

CIFAR-10 — Exercices 6 & 7

Rapport et justification des choix

Matis Codjia
matis.codjia@epita.fr

Simon Naulet
simon.naulet@epita.fr

Brendan Martin
brendan.martin@epita.fr

Lilou Mayot
lilou.mayot@epita.fr

4 juillet 2026

Résumé

On classe les images CIFAR-10 sans réseau de neurones, avec des méthodes classiques d'optimisation et d'algèbre linéaire (SVM, noyaux, PCA, K -means). L'exercice 6 traite la classification supervisée (SVM, puis passage à l'échelle par Nyström); l'exercice 7 apprend des représentations non supervisées, évaluées par sonde linéaire. Toutes les valeurs numériques proviennent du notebook `cifar_ex6_7.ipynb`.

1 Jeu de données et problème

Présentation (CIFAR-10). Le jeu de données est CIFAR-10, téléchargé depuis <https://www.cs.toronto.edu/~kriz/cifar.html> (A. Krizhevsky, 2009). Il contient 60 000 petites photographies couleur de 32×32 pixels, réparties en 10 classes d'objets du quotidien : avion, automobile, oiseau, chat, cerf, chien, grenouille, cheval, bateau, camion. Chaque image est fournie comme un vecteur de $d = 32 \times 32 \times 3 = 3072$ entiers dans $[0, 255]$ (les trois canaux RVB mis bout à bout, dans cet ordre), stocké dans des fichiers `pickle`. Les classes sont **équilibrées** (6 000 images chacune) et le découpage officiel donne 50 000 images d'entraînement et 10 000 de test. Point moins évident pour qui ne connaît pas ces données : aucune variable n'a de sens prise isolément (un pixel seul n'apprend rien), l'information est dans les *corrélations spatiales* entre pixels voisins; de plus certaines classes sont visuellement proches (chat/chien, automobile/camion), ce qui annonce des confusions.

Problème. On résout une **classification multi-classes** : prédire l'étiquette $y \in \{0, \dots, 9\}$ (la classe de l'objet) à partir des seules 3072 intensités de pixels x , sans information annexe. C'est une brique de base de la vision par ordinateur (tri et étiquetage automatique d'images, modération de contenu, indexation visuelle); CIFAR-10 sert surtout de banc d'essai standard pour *comparer* des méthodes, ce qui est précisément notre objectif.

2 Cadre et protocole

On note les données $\{(x_i, y_i)\}_{i=1}^n$, $x_i \in \mathbb{R}^d$, $d = 3072$. Le SVM à noyau *exact* demande une matrice de Gram $n \times n$ (~ 20 Go pour $n = 50\,000$) : on l'évalue donc sur un sous-échantillon $10\,000/2\,000$, tandis que les méthodes linéaires, Nyström, PCA et K -means exploitent les données complètes.

Risque réel vs risque empirique. On cherche un classifieur f de petit *risque réel* $R(f) = \mathbb{E}_{(x,y) \sim p} [\ell(f(x), y)]$, espérance de la perte sur la vraie distribution p (inconnue), ici avec la perte 0/1. Comme p est inaccessible, on ne dispose que du *risque empirique* $R_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)$, moyenne sur l'échantillon, que les modèles minimisent (éventuellement régularisé). L'écart $R(f) - R_n(f)$ est l'erreur de *généralisation* : un modèle qui colle au train (R_n petit) mais généralise mal (R grand) *sur-apprend*. Le jeu de test, jamais utilisé pour l'apprentissage ni le réglage, fournit un estimateur non biaisé de $R(f)$: c'est pourquoi on ne le consulte qu'une fois, et l'accuracy test rapportée estime $1 - R(f)$.

Préparation des données. Les pixels sont **standardisés** (centrage/réduction par variable) avant les modèles à distance (k -NN, SVM) : sans cela, les coordonnées de plus forte variance domineraient le calcul des distances et du noyau. Pour la PCA on centre simplement les données (la covariance n'a de sens que centrée).

Hyperparamètres. Pour le SVM RBF, on sélectionne le couple (C, γ) par **validation croisée** (**GridSearchCV**, 3 plis stratifiés) sur la grille $C \in \{1, 10, 100\}$, $\gamma \in \{\text{scale}, 10^{-3}, 10^{-2}\}$. Une recherche exhaustive sur 50 000 images avec noyau exact étant trop coûteuse, cette CV se fait sur un sous-échantillon d'entraînement (3 000 images) ; le meilleur couple est ensuite ré-entraîné sur les 10 000 images, puis évalué *une seule fois* sur le test. Pour les méthodes passant à l'échelle (Nyström, K -means), trop lourdes pour une grille complète, on conserve des valeurs usuelles. Dans tous les cas, le jeu de test ne sert jamais à choisir un modèle ni un hyperparamètre.

3 Exercice 6 — Classification supervisée

3.1 Baselines

On situe trois baselines de référence (sur pixels bruts) :

- **k -NN** : vote majoritaire des k plus proches voisins ; aucune optimisation, illustration du compromis biais-variance.
- **Régression softmax** : $p(y = c \mid x) = e^{w_c^\top x} / \sum_j e^{w_j^\top x}$, minimisation de l'entropie croisée $-\sum_i \log p(y_i \mid x_i)$, fonction *convexe* à gradient explicite.
- **SVM linéaire** : perte hinge régularisée $\frac{1}{2} \|w\|^2 + C \sum_i \max(0, 1 - y_i(w^\top x_i + b))$ (cf. 3.2).

3.2 SVM à marge maximale : dérivation

Primal (marge dure). Pour des données séparables, $y_i \in \{\pm 1\}$, l'hyperplan $w^\top x + b = 0$ a une marge $2/\|w\|$; la maximiser revient à

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.c.} \quad y_i(w^\top x_i + b) \geq 1 \quad \forall i. \quad (1)$$

Marge souple. Pour des données non séparables, on relâche par des écarts $\xi_i \geq 0$:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i \quad \text{s.c.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad (2)$$

dont l'optimum donne $\xi_i = \max(0, 1 - y_i(w^\top x_i + b))$: la perte *hinge*.

Lagrangien. Avec $\alpha_i \geq 0$ (marge) et $\mu_i \geq 0$ ($\xi_i \geq 0$),

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + C \sum_i \xi_i - \sum_i \alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i.$$

L'annulation des dérivées donne les conditions stationnaires

$$w = \sum_i \alpha_i y_i x_i, \quad \sum_i \alpha_i y_i = 0, \quad \alpha_i = C - \mu_i. \quad (3)$$

Dual. En réinjectant,

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \quad \text{s.c.} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0. \quad (4)$$

Problème quadratique concave où les données n'interviennent *que* par produits scalaires.

KKT et vecteurs supports. La complémentarité $\alpha_i [y_i (w^\top x_i + b) - 1 + \xi_i] = 0$ impose $\alpha_i \neq 0$ uniquement pour les points sur ou dans la marge — les **vecteurs supports** : la solution n'en dépend que d'eux (96 % des points ici, donnée difficile).

Kernel trick. Tout passant par $\langle x_i, x_j \rangle$, on substitue un noyau $k(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle$. Pour un noyau symétrique défini positif, une telle application φ existe (théorème de Mercer), et la solution s'écrit $w = \sum_i \alpha_i y_i \varphi(x_i)$, d'où le classifieur $f(x) = \sum_i \alpha_i y_i k(x_i, x) + b$. Le RBF $k(x, x') = \exp(-\gamma \|x - x'\|^2)$ correspond à un φ de dimension infinie.

3.3 Passage à l'échelle : approximation de Nyström

La matrice de Gram exacte $K \in \mathbb{R}^{n \times n}$ est inabordable pour $n = 50\,000$. On l'approche par une matrice de **rang faible** $m \ll n$. Soit m points de référence (*landmarks*) et les blocs

$$C \in \mathbb{R}^{n \times m} \text{ (noyau tous } \times \text{ landmarks)}, \quad W \in \mathbb{R}^{m \times m} \text{ (landmarks } \times \text{ landmarks)},$$

$$\boxed{\tilde{K} = C W^+ C^\top} \quad (\text{rang} \leq m), \quad (5)$$

W^+ étant le pseudo-inverse. **Carte de features explicite** : diagonalisons $W = U \Lambda U^\top$ et posons $Z = C U \Lambda^{-1/2} \in \mathbb{R}^{n \times m}$. Alors

$$Z Z^\top = C U \Lambda^{-1} U^\top C^\top = C W^+ C^\top = \tilde{K}, \quad (6)$$

si bien que $\langle z_i, z_j \rangle \approx k(x_i, x_j)$: on a *rendu le noyau explicite*. Le SVM à noyau devient un SVM *linéaire* dans $\mathbb{R}^m$ (coût $O(nm)$), applicable aux 50 000 images sans jamais former K .

Pourquoi cela fonctionne. Si le spectre de K décroît vite (cas du RBF), K est presque de rang faible et $\tilde{K}$ en est une bonne reconstruction, comme pour Eckart–Young en PCA (§4.1). L'erreur relative mesurée $\|K - \tilde{K}\|_F / \|K\|_F$ vaut 0.167, 0.093, 0.059 pour $m = 50, 150, 400$: elle chute vite, ce qui confirme cette décroissance du spectre.

3.4 Résultats et choix

Modèle	données	acc. test
k -NN ($k=10$)	10k/2k	0.281
Softmax	10k/2k	0.292
SVM linéaire (hinge)	10k/2k	0.308
SVM RBF <i>exact</i>	10k/2k	0.479
Nyström RBF $m=500$	50k/10k	0.481
Nyström RBF $m=1000$	50k/10k	0.504

Choix. Le RBF est retenu (non-linéarité nécessaire : le linéaire plafonne à 0.31). Nyström sur 50 000 atteint la précision du RBF exact sur 10 000 *pour un coût comparable* : à budget égal, il vaut mieux plus de données via une approximation contrôlée que le noyau exact sur peu de données. En pixels bruts on plafonne toutefois vers 0.50 : la limite est la *représentation*, d'où l'exercice 7.

4 Exercice 7 — Représentations non supervisées

On apprend une application φ *sans étiquettes*, puis on teste les latents par une **sonde linéaire** (classifieur linéaire sur représentations gelées, 10 000 exemples d’entraînement, test complet). Une bonne représentation rend la tâche *linéairement* séparable.

Choix du scoring. L’étape non supervisée (PCA, K -means) n’utilise pas les étiquettes ; on ne peut donc pas la noter directement par une précision. On choisit comme score la **précision de la sonde linéaire** : elle mesure exactement ce qui nous intéresse, à savoir si la représentation rend les classes *linéairement* séparables, et reste comparable d’une représentation à l’autre (même classifieur, même taille d’entraînement). Une mesure non supervisée interne comme l’inertie du K -means renseignerait sur la compacité des amas mais pas sur leur utilité pour la classification, qui est notre but.

4.1 PCA : dérivation (Eckart–Young)

Sur données centrées, covariance $\Sigma = \frac{1}{n} X^\top X = U \Lambda U^\top$, $\lambda_1 \geq \dots \geq \lambda_d \geq 0$. Deux lectures équivalentes : *variance maximale* ($\arg \max_{\|u\|=1} u^\top \Sigma u = u_1$, quotient de Rayleigh) et *reconstruction minimale* ($\min \sum_i \|x_i - Px_i\|^2$ sur les projecteurs de rang k), donnant le même $U_k = [u_1, \dots, u_k]$.

Théorème d’Eckart–Young. $X_k = XU_k U_k^\top$ est la meilleure approximation de rang k de X (normes de Frobenius et spectrale), d’erreur $\sum_{j>k} \lambda_j$. C’est ce qui justifie de garder les premières composantes comme représentation. Mesuré : variance cumulée 0.86 à $k=64$, 0.96 à $k=256$.

4.2 Dictionnaire K -means (Coates & Ng)

K -means apprend K centroïdes minimisant $\sum_i \min_k \|p_i - c_k\|^2$ (algorithme de Lloyd : assignation $\leftrightarrow$ moyenne, décroissance monotone, convergence vers un minimum local) : une quantification vectorielle servant de *dictionnaire*. La métrique est la **distance euclidienne**, cohérente avec l’objectif quadratique de K -means et appliquée *après* blanchiment ZCA, qui décorrèle les pixels pour que cette distance ne soit pas faussée par leurs corrélations. Pipeline :

1. patches $6 \times 6 \times 3$ aléatoires, normalisés en contraste (centrage + variance unité) ;
2. **blanchiment ZCA** $p \mapsto Wp$, $W = U(\Lambda + \varepsilon I)^{-1/2} U^\top$ (covariance des patches) : décorrélacion — encore le théorème spectral ;
3. dictionnaire : K -means sur patches blanchis ;
4. encodage *triangle* $f_k(p) = \max(0, \bar{d}(p) - \|p - c_k\|)$ (code parcimonieux, non négatif), $\bar{d}$ distance moyenne aux centroïdes ;
5. **pooling** par quadrants $2 \times 2 \Rightarrow 4K$ features, passées à un SVM linéaire.

Intuition : blanchiment + K -means fabriquent des détecteurs de bords/couleurs ; le pooling apporte l’invariance ; la tâche devient linéairement séparable.

4.3 Résultats et choix

Représentation	dim	acc. test (sonde lin.)
Pixels bruts	3072	0.323
PCA	256	0.380
Dictionnaire K-means	1024	0.659

Choix. À classifieur *linéaire fixé*, passer des pixels au dictionnaire K -means double quasiment la précision ($0.32 \rightarrow 0.66$), et sans étiquette : la difficulté de CIFAR est surtout dans la représentation, pas dans le classifieur. Augmenter K (jusqu’à 1600) pousse vers ~ 0.77 (Coates & Ng) ; on garde $K=256$ pour un temps de calcul modéré.

5 Conclusion

On retrouve deux outils principaux. D'une part l'optimisation convexe : le SVM se résout via son dual (KKT, vecteurs supports), le kernel trick déplace la non-linéarité, et Nyström permet le passage à l'échelle. D'autre part la diagonalisation des matrices symétriques (théorème spectral), qui sert pour la PCA, le blanchiment ZCA et le bloc W de Nyström. Le gain décisif vient finalement de l'apprentissage non supervisé de représentations (K -means, PCA) plutôt que du choix du classifieur.