

FTML 2027 — Projet

Matis Codjia
matis.codjia@epita.fr

Simon Naulet
simon.naulet@epita.fr

Brendan Martin
brendan.martin@epita.fr

Lilou Mayot
lilou.mayot@epita.fr

Résumé

Les exercices de 1 à 3 du projet sont développés dans leur parties, les exercices 4 à 5 étant dans leur notebooks spécifiques. Pour les exercices 6 et 7, on classe les images CIFAR-10 sans réseau de neurones, avec des méthodes classiques d'optimisation et d'algèbre linéaire (SVM, noyaux, PCA, K -means). L'exercice 6 traite la classification supervisée (SVM, puis passage à l'échelle par Nyström) ; l'exercice 7 apprend des représentations non supervisées, évaluées par sonde linéaire. Toutes les valeurs numériques proviennent du notebook `cifar_ex6_7.ipynb`.

Table des matières

1	Bayes estimator and Bayes risk	1
2	Bayes risk with absolute loss	3
3	Expected value of empirical risk for OLS	5
4	Jeu de données et problème	8
5	Cadre et protocole	9
6	Exercice 6 — Classification supervisée	9
6.1	Baselines	9
6.2	SVM à marge maximale : dérivation	10
6.3	Passage à l'échelle : approximation de Nyström	10
6.4	Résultats et choix	11
7	Exercice 7 — Représentations non supervisées	11
7.1	PCA : dérivation (Eckart–Young)	11
7.2	Dictionnaire K -means (Coates & Ng)	11
7.3	Résultats et choix	12
8	Conclusion	12

Convention : sauf mention contraire, toutes les espérances et probabilités conditionnelles sont prises par rapport à la loi conditionnelle de Y sachant $X = x$, pour $x \in \mathcal{X}$ fixé.

1 Bayes estimator and Bayes risk

Question 1 (M)

Setting proposé. On considère le cadre de régression suivant.

- Espace d'entrée : $\mathcal{X} = [30, 240]$, représentant un nombre d'images par seconde (FPS) ciblé par un utilisateur dans les paramètres d'un jeu vidéo.
- Espace de sortie : $\mathcal{Y} = \mathbb{R}_+$, représentant la puissance consommée par une carte graphique, en Watts.
- Loi jointe de (X, Y) : $X \sim \mathcal{U}([30, 240])$, et conditionnellement à $X = x$,

$$Y \mid X = x = a + bx + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2),$$

où ε est indépendant de X , et $a, b, \sigma > 0$ sont des constantes fixées. Le bruit ε modélise les fluctuations de mesure (charge CPU concurrente, throttling thermique, etc.).

- Fonction de perte : la perte quadratique,

$$l(\hat{y}, y) = (\hat{y} - y)^2.$$

Calcul du prédicteur de Bayes.

Proposition 1. *Pour la perte quadratique, le prédicteur de Bayes vérifie, pour tout $x \in \mathcal{X}$,*

$$f^*(x) = \mathbb{E}[Y \mid X = x].$$

Démonstration. Par définition, f^* minimise le risque réel $\mathbb{E}_{(X,Y)}[(f(X) - Y)^2]$ parmi toutes les fonctions $f : \mathcal{X} \rightarrow \mathcal{Y}$. En conditionnant par rapport à X ,

$$\mathbb{E}_{(X,Y)}[(f(X) - Y)^2] = \mathbb{E}_X \left[\mathbb{E}_{Y|X}[(f(X) - Y)^2 \mid X] \right].$$

Comme $f(X)$ ne dépend que de X , il suffit de minimiser, pour chaque x fixé, la quantité

$$h(c) = \mathbb{E}_{Y|X}[(c - Y)^2 \mid X = x]$$

par rapport à $c \in \mathbb{R}$. On développe :

$$h(c) = \mathbb{E}[(c - \mathbb{E}[Y \mid X = x])^2] + 2(c - \mathbb{E}[Y \mid X = x]) \underbrace{\mathbb{E}[\mathbb{E}[Y \mid X = x] - Y \mid X = x]}_{=0} + \text{Var}(Y \mid X = x),$$

où le terme croisé est nul car $\mathbb{E}[Y \mid X = x] - Y$ est centré conditionnellement à $X = x$. On obtient ainsi

$$h(c) = (c - \mathbb{E}[Y \mid X = x])^2 + \text{Var}(Y \mid X = x),$$

qui est minimal (et atteint son minimum en un point unique) en $c^* = \mathbb{E}[Y \mid X = x]$. D'où $f^*(x) = \mathbb{E}[Y \mid X = x]$. $\square$

Dans notre setting, $Y \mid X = x \sim \mathcal{N}(a + bx, \sigma^2)$, donc $\mathbb{E}[Y \mid X = x] = a + bx$, et

$$\boxed{f^*(x) = a + bx}.$$

Calcul du risque de Bayes. Le risque de Bayes est le risque réel évalué en f^* :

$$R^* = \mathbb{E}_{(X,Y)}[(f^*(X) - Y)^2] = \mathbb{E}[(a + bX - (a + bX + \varepsilon))^2] = \mathbb{E}[\varepsilon^2] = \text{Var}(\varepsilon) = \sigma^2,$$

puisque ε est centré. D'où

$$\boxed{R^* = \sigma^2}.$$

Remarque. La Question 2 (C) de cet exercice (proposer un estimateur $\tilde{f}$ différent de f^* et comparer leurs erreurs de généralisation empiriques) est une question de simulation. Le code correspondant est fourni séparément sous forme de notebook.

2 Bayes risk with absolute loss

Question 0 (M)

On cherche une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ dont la dérivée s'annule en un point x_0 sans que x_0 soit un extremum local.

Proposition 2. *La fonction $f(x) = x^3$ convient, avec $x_0 = 0$.*

Démonstration. On a $f'(x) = 3x^2$, donc $f'(0) = 0$. Cependant, pour tout $x < 0$, $f(x) = x^3 < 0 = f(0)$, et pour tout $x > 0$, $f(x) = x^3 > 0 = f(0)$. Ainsi, dans tout voisinage de 0, f prend des valeurs strictement inférieures et strictement supérieures à $f(0)$: $x_0 = 0$ n'est ni un minimum local, ni un maximum local. C'est un point d'inflexion à tangente horizontale. $\square$

Question 1 (M + C)

On cherche un setting pour lequel $f_{\text{absolue}}^* \neq f_{\text{carrée}}^*$.

Setting proposé. On prend $\mathcal{X} = \mathbb{R}$, $\mathcal{Y} = \mathbb{R}$, X de loi quelconque, et conditionnellement à $X = x$:

$$Y \mid X = x = x + \varepsilon, \quad \varepsilon \sim \text{Exp}(1) \text{ (loi exponentielle de paramètre 1),}$$

avec ε indépendant de X . La densité de ε est $p(t) = e^{-t} \mathbf{1}_{t \geq 0}$.

Le bruit ε étant asymétrique, sa moyenne et sa médiane diffèrent :

$$\mathbb{E}[\varepsilon] = 1, \quad \text{med}(\varepsilon) = \ln 2 \approx 0,693.$$

(La médiane de $\text{Exp}(1)$ vérifie $1 - e^{-m} = \frac{1}{2}$, soit $m = \ln 2$.)

Par conséquent :

$$f_{\text{carrée}}^*(x) = \mathbb{E}[Y \mid X = x] = x + 1, \quad f_{\text{absolue}}^*(x) = \text{med}(Y \mid X = x) = x + \ln 2$$

(le second résultat étant justifié rigoureusement en Question 2). Comme $\ln 2 \neq 1$, les deux prédicteurs de Bayes sont distincts.

Comparaison explicite des risques en perte absolue. On va montrer directement que $f_{\text{carrée}}^*$, bien qu'optimal pour la perte quadratique, est *sous-optimal* pour la perte absolue.

Pour $c \geq 0$ fixé, calculons $\mathbb{E}|\varepsilon - c|$ avec $\varepsilon \sim \text{Exp}(1)$:

$$\mathbb{E}|\varepsilon - c| = \int_0^c (c - t)e^{-t} dt + \int_c^{+\infty} (t - c)e^{-t} dt.$$

Pour la première intégrale, en utilisant $\int_0^c te^{-t} dt = 1 - (c + 1)e^{-c}$:

$$\int_0^c (c - t)e^{-t} dt = c(1 - e^{-c}) - [1 - (c + 1)e^{-c}] = c - 1 + e^{-c}.$$

Pour la seconde, le changement de variable $u = t - c$ donne :

$$\int_c^{+\infty} (t - c)e^{-t} dt = e^{-c} \int_0^{+\infty} ue^{-u} du = e^{-c}.$$

D'où, pour tout $c \geq 0$:

$$\mathbb{E}|\varepsilon - c| = c - 1 + 2e^{-c}.$$

On évalue cette expression aux deux candidats :

$$R_{l_{\text{absolue}}}(f_{l_{\text{carrée}}}^*) = \mathbb{E}|1 - \varepsilon| = \mathbb{E}|\varepsilon - 1| = 1 - 1 + 2e^{-1} = \frac{2}{e} \approx 0,736,$$

$$R_{l_{\text{absolue}}}(f_{l_{\text{absolue}}}^*) = \mathbb{E}|\varepsilon - \ln 2| = \ln 2 - 1 + 2e^{-\ln 2} = \ln 2 - 1 + 2 \cdot \frac{1}{2} = \ln 2 \approx 0,693.$$

(On a utilisé $|f_{l_{\text{carrée}}}^*(X) - Y| = |(X + 1) - (X + \varepsilon)| = |1 - \varepsilon|$, et de même pour le second terme.)

On obtient donc

$$R_{l_{\text{absolue}}}(f_{l_{\text{absolue}}}^*) = \ln 2 < \frac{2}{e} = R_{l_{\text{absolue}}}(f_{l_{\text{carrée}}}^*),$$

ce qui confirme, sur un exemple totalement explicite, que le prédicteur optimal pour la perte quadratique n'est pas optimal pour la perte absolue. La vérification numérique par simulation (génération d'échantillons, calcul des risques empiriques) est fournie dans le notebook associé.

Question 2 (M) — Cas général

Cadre et hypothèses. Pour $x \in \mathcal{X}$ fixé, on suppose que $Y \mid X = x$ admet une densité continue $p_{Y \mid X=x}$, et que $Y \mid X = x$ admet un moment d'ordre 1, c'est-à-dire $\mathbb{E}[|Y| \mid X = x] < +\infty$. On note F la fonction de répartition associée à $p_{Y \mid X=x}$, et l'on cherche

$$f_{l_{\text{absolue}}}^*(x) = \arg \min_{z \in \mathbb{R}} g(z), \quad g(z) = \int_{\mathbb{R}} |y - z| p_{Y \mid X=x}(y) dy.$$

Bonne définition de g . Pour $z \in \mathbb{R}$ fixé, l'inégalité triangulaire donne $|y - z| \leq |y| + |z|$, donc

$$g(z) \leq \mathbb{E}[|Y| \mid X = x] + |z| < +\infty$$

par hypothèse de moment d'ordre 1. Ainsi $g(z)$ est bien définie (finie) pour tout $z \in \mathbb{R}$.

Calcul de $g'(z)$. On découpe l'intégrale en deux morceaux selon la position de y par rapport à z :

$$g(z) = \int_{-\infty}^z (z - y) p(y) dy + \int_z^{+\infty} (y - z) p(y) dy,$$

où l'on note $p = p_{Y \mid X=x}$ pour simplifier. La densité p étant continue, chacune de ces deux intégrales est dérivable par rapport à z (théorème de dérivation sous le signe intégrale, ou directement par la règle de Leibniz pour une borne variable) :

- Pour le premier terme, $\frac{d}{dz} \int_{-\infty}^z (z - y) p(y) dy = \underbrace{(z - z)p(z)}_{=0} + \int_{-\infty}^z p(y) dy = F(z),$
- Pour le second, $\frac{d}{dz} \int_z^{+\infty} (y - z) p(y) dy = \underbrace{-(z - z)p(z)}_{=0} - \int_z^{+\infty} p(y) dy = -(1 - F(z)).$

(Dans chaque cas, le terme de bord provenant de la dérivation de la borne z s'annule car l'intégrande $(z - y)$, resp. $(y - z)$, vaut 0 en $y = z$.)

On obtient donc, pour tout $z \in \mathbb{R}$:

$$g'(z) = F(z) - (1 - F(z)) = 2F(z) - 1.$$

Annulation de la dérivée.

$$g'(z) = 0 \iff F(z) = \frac{1}{2} \iff z \text{ est une médiane de } Y \mid X = x.$$

Nature du point critique. Comme p est continue, F est de classe $\mathcal{C}^1$ et g est de classe $\mathcal{C}^2$, avec

$$g''(z) = 2p(z) \geq 0 \quad \text{pour tout } z.$$

g est donc convexe sur $\mathbb{R}$: tout point critique de g est un minimum global (et non un point d'inflexion comme à la Question 0, puisque $g'' \geq 0$ partout et pas seulement en un point). Si $g'' > 0$ en un voisinage du point critique (densité strictement positive), il s'agit même d'un minimum strict local ; la convexité globale garantit dans tous les cas qu'il s'agit d'un minimum global de g .

Conclusion.

$$\boxed{f_{\text{absolue}}^*(x) = \text{med}(Y \mid X = x)}$$

pour tout $x \in \mathcal{X}$, c'est-à-dire tout réel z vérifiant $F(z) = 1/2$ (un tel z existe et est unique dès que F est strictement croissante, ce qui est le cas si $p > 0$ sur le support de la loi).

3 Expected value of empirical risk for OLS

Rappel du contexte

On se place dans le cadre fixed design, modèle linéaire : $y = X\theta^* + \varepsilon$, avec ε un vecteur de bruit centré, de matrice de covariance $\sigma^2 I_n$, à composantes indépendantes. $X \in \mathbb{R}^{n \times d}$ est injective (donc $d \leq n$ et $X^T X$ est inversible). L'estimateur OLS est $\hat{\theta} = (X^T X)^{-1} X^T y$. On veut établir

$$\mathbb{E}[R_X(\hat{\theta})] = \frac{n-d}{n} \sigma^2. \quad (\text{Proposition 1})$$

Question 1 (M)

Comparaison avec le risque de Bayes. Pour la perte quadratique et ce modèle linéaire (bruit centré de variance σ^2), le prédicteur de Bayes est $f^*(x) = x^T \theta^*$ (cf. Exercice 1, Question 1, appliqué ici), et le risque de Bayes associé est

$$R^* = \sigma^2.$$

On compare cette quantité à $\mathbb{E}[R_X(\hat{\theta})] = \frac{n-d}{n} \sigma^2$. Puisque $0 < d \leq n$ (et en pratique $d < n$ strictement, sinon $X^T X$ n'est inversible pour le cas limite seulement si $d = n$ injective ce qui reste possible mais $\frac{n-d}{n} = 0$), on a

$$0 \leq \frac{n-d}{n} < 1 \quad (\text{dès que } d \geq 1),$$

donc

$$\boxed{\mathbb{E}[R_X(\hat{\theta})] = \frac{n-d}{n} \sigma^2 \leq \sigma^2 = R^*}.$$

Interprétation. Le risque empirique moyen de l'estimateur OLS, *évalué sur les mêmes points X que ceux ayant servi à l'estimation* (fixed design), **sous-estime** le risque de Bayes (= la variance irréductible du bruit).

- **En fonction de d** : plus le nombre de paramètres d est grand (modèle plus flexible), plus l'écart $\frac{d}{n} \sigma^2$ entre risque de Bayes et risque empirique espéré est important : le modèle a plus de degrés de liberté pour s'ajuster au bruit de l'échantillon (sur-apprentissage). À la limite $d = n$ (saturée, X carrée inversible), $\mathbb{E}[R_X(\hat{\theta})] = 0$: le modèle interpole parfaitement les données d'entraînement et le risque empirique ne reflète plus du tout l'erreur de généralisation.

- **En fonction de n** : pour d fixé, $\frac{n-d}{n} = 1 - \frac{d}{n} \xrightarrow{n \rightarrow \infty} 1$. Le biais d'optimisme s'atténue lorsque l'on dispose de davantage de données : l'estimation $\hat{\theta}$ se rapproche de θ^* et le risque empirique tend vers le risque de Bayes.

Question 2 (M)

On veut montrer que

$$\mathbb{E}[R_n(\hat{\theta})] = \mathbb{E}_\varepsilon \left[\frac{1}{n} \|(I_n - X(X^T X)^{-1} X^T) \varepsilon\|^2 \right].$$

Démonstration. Par définition, $R_n(\hat{\theta}) = \frac{1}{n} \|y - X\hat{\theta}\|^2$. On exprime le résidu $y - X\hat{\theta}$ en fonction de ε . D'une part, $y = X\theta^* + \varepsilon$. D'autre part,

$$\hat{\theta} = (X^T X)^{-1} X^T y = (X^T X)^{-1} X^T (X\theta^* + \varepsilon) = \theta^* + (X^T X)^{-1} X^T \varepsilon,$$

donc

$$X\hat{\theta} = X\theta^* + X(X^T X)^{-1} X^T \varepsilon.$$

On en déduit :

$$y - X\hat{\theta} = (X\theta^* + \varepsilon) - (X\theta^* + X(X^T X)^{-1} X^T \varepsilon) = \varepsilon - X(X^T X)^{-1} X^T \varepsilon = (I_n - X(X^T X)^{-1} X^T) \varepsilon.$$

Ainsi, en notant $A = I_n - X(X^T X)^{-1} X^T$, on a $y - X\hat{\theta} = A\varepsilon$, donc

$$R_n(\hat{\theta}) = \frac{1}{n} \|A\varepsilon\|^2.$$

Cette égalité étant vraie pour toute réalisation de ε (donc de y), elle reste vraie en espérance :

$$\mathbb{E}[R_n(\hat{\theta})] = \mathbb{E}_\varepsilon \left[\frac{1}{n} \|A\varepsilon\|^2 \right].$$

□

Question 3 (M)

Pour $A \in \mathbb{R}^{n \times n}$, on veut montrer

$$\sum_{(i,j) \in [1,n]^2} A_{ij}^2 = \text{tr}(A^T A).$$

Démonstration. Par définition du produit matriciel et de la trace,

$$\text{tr}(A^T A) = \sum_{i=1}^n (A^T A)_{ii} = \sum_{i=1}^n \sum_{j=1}^n (A^T)_{ij} A_{ji} = \sum_{i=1}^n \sum_{j=1}^n A_{ji} A_{ji} = \sum_{i=1}^n \sum_{j=1}^n A_{ji}^2,$$

où l'on a utilisé $(A^T)_{ij} = A_{ji}$. En renommant les indices de sommation ($i \leftrightarrow j$), on obtient bien

$$\text{tr}(A^T A) = \sum_{(i,j) \in [1,n]^2} A_{ij}^2.$$

□

Question 4 (M)

On veut montrer que pour $A \in \mathbb{R}^{n \times n}$ déterministe et ε comme dans le modèle (composantes indépendantes, centrées, de variance σ^2),

$$\mathbb{E}_\varepsilon \left[\frac{1}{n} \|A\varepsilon\|^2 \right] = \frac{\sigma^2}{n} \text{tr}(A^T A).$$

Démonstration. On note $(A\varepsilon)_i = \sum_{j=1}^n A_{ij}\varepsilon_j$ la i -ème coordonnée de $A\varepsilon$. Alors

$$\|A\varepsilon\|^2 = \sum_{i=1}^n (A\varepsilon)_i^2 = \sum_{i=1}^n \left(\sum_{j=1}^n A_{ij}\varepsilon_j \right)^2 = \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n A_{ij}A_{ik} \varepsilon_j \varepsilon_k.$$

On prend l'espérance, en utilisant la linéarité et le fait que les $A_{ij}A_{ik}$ sont des constantes :

$$\mathbb{E}[\|A\varepsilon\|^2] = \sum_{i,j,k} A_{ij}A_{ik} \mathbb{E}[\varepsilon_j \varepsilon_k].$$

Or, par indépendance et centrage des ε_j : $\mathbb{E}[\varepsilon_j \varepsilon_k] = 0$ si $j \neq k$, et $\mathbb{E}[\varepsilon_j^2] = \text{Var}(\varepsilon_j) = \sigma^2$ si $j = k$. C'est-à-dire $\mathbb{E}[\varepsilon_j \varepsilon_k] = \sigma^2 \delta_{jk}$. La double somme sur j, k se réduit donc à $j = k$:

$$\mathbb{E}[\|A\varepsilon\|^2] = \sum_{i=1}^n \sum_{j=1}^n A_{ij}^2 \sigma^2 = \sigma^2 \sum_{(i,j)} A_{ij}^2 \stackrel{(\text{Q3})}{=} \sigma^2 \text{tr}(A^T A).$$

En divisant par n , on conclut :

$$\mathbb{E}_\varepsilon \left[\frac{1}{n} \|A\varepsilon\|^2 \right] = \frac{\sigma^2}{n} \text{tr}(A^T A).$$

□

Question 5 (M)

On note $A = I_n - X(X^T X)^{-1}X^T$, et on veut montrer $A^T A = A$.

Démonstration. On pose $P = X(X^T X)^{-1}X^T$, tel que $A = I_n - P$. On montre deux propriétés de P .

P est symétrique : comme $X^T X$ est symétrique, son inverse $(X^T X)^{-1}$ l'est aussi, donc

$$P^T = X((X^T X)^{-1})^T X^T = X(X^T X)^{-1}X^T = P.$$

P est idempotente ($P^2 = P$) :

$$P^2 = X(X^T X)^{-1}X^T X(X^T X)^{-1}X^T = X(X^T X)^{-1} \underbrace{(X^T X)(X^T X)^{-1}}_{=I_d} X^T = X(X^T X)^{-1}X^T = P.$$

On en déduit que $A = I_n - P$ est elle-même symétrique :

$$A^T = I_n^T - P^T = I_n - P = A,$$

et idempotente :

$$A^2 = (I_n - P)^2 = I_n - 2P + P^2 = I_n - 2P + P = I_n - P = A.$$

Finalement,

$$A^T A = A \cdot A = A^2 = A.$$

□

Question 6 (M) — Conclusion

En combinant les résultats précédents :

$$\mathbb{E}[R_n(\hat{\theta})] \stackrel{(Q2)}{=} \mathbb{E}_\varepsilon \left[\frac{1}{n} \|A\varepsilon\|^2 \right] \stackrel{(Q4)}{=} \frac{\sigma^2}{n} \text{tr}(A^T A) \stackrel{(Q5)}{=} \frac{\sigma^2}{n} \text{tr}(A).$$

Il reste à calculer $\text{tr}(A)$:

$$\text{tr}(A) = \text{tr}(I_n - P) = \text{tr}(I_n) - \text{tr}(P) = n - \text{tr}(X(X^T X)^{-1} X^T).$$

Par invariance cyclique de la trace ($\text{tr}(UV) = \text{tr}(VU)$) :

$$\text{tr}(X(X^T X)^{-1} X^T) = \text{tr}((X^T X)^{-1} X^T X) = \text{tr}(I_d) = d.$$

D'où $\text{tr}(A) = n - d$, et finalement

$$\boxed{\mathbb{E}[R_n(\hat{\theta})] = \mathbb{E}[R_X(\hat{\theta})] = \frac{n-d}{n} \sigma^2},$$

ce qui établit la Proposition 1.

Question 7 (M)

On cherche $\mathbb{E} \left[\frac{\|y - X\hat{\theta}\|^2}{n-d} \right]$.

Démonstration. On a établi $\mathbb{E}[R_n(\hat{\theta})] = \mathbb{E} \left[\frac{1}{n} \|y - X\hat{\theta}\|^2 \right] = \frac{n-d}{n} \sigma^2$, donc par linéarité de l'espérance :

$$\mathbb{E}[\|y - X\hat{\theta}\|^2] = (n-d) \sigma^2.$$

En divisant par la constante (déterministe) $n-d > 0$:

$$\boxed{\mathbb{E} \left[\frac{\|y - X\hat{\theta}\|^2}{n-d} \right] = \sigma^2}.$$

□

Remarque. Ce résultat fournit un **estimateur sans biais** de σ^2 , à savoir $\hat{\sigma}^2 = \frac{\|y - X\hat{\theta}\|^2}{n-d}$ (l'estimateur classique de la variance résiduelle en régression linéaire, avec correction des degrés de liberté). La Question 8 (C) propose une vérification numérique de ce résultat par simulation ; le code correspondant est fourni séparément.

4 Jeu de données et problème

Présentation (CIFAR-10). Le jeu de données est CIFAR-10, téléchargé depuis <https://www.cs.toronto.edu/~kriz/cifar.html> (A. Krizhevsky, 2009). Il contient 60 000 petites photographies couleur de 32×32 pixels, réparties en 10 classes d'objets du quotidien : avion, automobile, oiseau, chat, cerf, chien, grenouille, cheval, bateau, camion. Chaque image est fournie comme un vecteur de $d = 32 \times 32 \times 3 = 3072$ entiers dans $[0, 255]$ (les trois canaux RVB mis bout à bout, dans cet ordre), stocké dans des fichiers **pickle**. Les classes sont **équilibrées** (6 000 images chacune) et le découpage officiel donne 50 000 images d'entraînement et 10 000 de test. Point moins évident pour qui ne connaît pas ces données : aucune variable n'a de sens prise isolément (un pixel seul n'apprend rien), l'information est dans les *corrélations spatiales* entre pixels voisins ; de plus certaines classes sont visuellement proches (chat/chien, automobile/camion), ce qui annonce des confusions.

Problème. On résout une **classification multi-classes** : prédire l'étiquette $y \in \{0, \dots, 9\}$ (la classe de l'objet) à partir des seules 3072 intensités de pixels x , sans information annexe. C'est une brique de base de la vision par ordinateur (tri et étiquetage automatique d'images, modération de contenu, indexation visuelle) ; CIFAR-10 sert surtout de banc d'essai standard pour *comparer* des méthodes, ce qui est précisément notre objectif.

5 Cadre et protocole

On note les données $\{(x_i, y_i)\}_{i=1}^n$, $x_i \in \mathbb{R}^d$, $d = 3072$. Le SVM à noyau *exact* demande une matrice de Gram $n \times n$ (~ 20 Go pour $n = 50\,000$) : on l'évalue donc sur un sous-échantillon $10\,000/2\,000$, tandis que les méthodes linéaires, Nyström, PCA et K -means exploitent les données complètes.

Risque réel vs risque empirique. On cherche un classifieur f de petit *risque réel* $R(f) = \mathbb{E}_{(x,y) \sim p}[\ell(f(x), y)]$, espérance de la perte sur la vraie distribution p (inconnue), ici avec la perte $0/1$. Comme p est inaccessible, on ne dispose que du *risque empirique* $R_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)$, moyenne sur l'échantillon, que les modèles minimisent (éventuellement régularisé). L'écart $R(f) - R_n(f)$ est l'erreur de *généralisation* : un modèle qui colle au train (R_n petit) mais généralise mal (R grand) *sur-apprend*. Le jeu de test, jamais utilisé pour l'apprentissage ni le réglage, fournit un estimateur non biaisé de $R(f)$: c'est pourquoi on ne le consulte qu'une fois, et l'accuracy test rapportée estime $1 - R(f)$.

Préparation des données. Les pixels sont **standardisés** (centrage/réduction par variable) avant les modèles à distance (k -NN, SVM) : sans cela, les coordonnées de plus forte variance domineraient le calcul des distances et du noyau. Pour la PCA on centre simplement les données (la covariance n'a de sens que centrée).

Hyperparamètres. Pour le SVM RBF, on sélectionne le couple (C, γ) par **validation croisée** (GridSearchCV, 3 plis stratifiés) sur la grille $C \in \{1, 10, 100\}$, $\gamma \in \{\text{scale}, 10^{-3}, 10^{-2}\}$. Une recherche exhaustive sur 50 000 images avec noyau exact étant trop coûteuse, cette CV se fait sur un sous-échantillon d'entraînement (3 000 images) ; le meilleur couple est ensuite ré-entraîné sur les 10 000 images, puis évalué *une seule fois* sur le test. Pour les méthodes passant à l'échelle (Nyström, K -means), trop lourdes pour une grille complète, on conserve des valeurs usuelles. Dans tous les cas, le jeu de test ne sert jamais à choisir un modèle ni un hyperparamètre.

6 Exercice 6 — Classification supervisée

6.1 Baselines

On situe trois baselines de référence (sur pixels bruts) :

- **k -NN** : vote majoritaire des k plus proches voisins ; aucune optimisation, illustration du compromis biais-variance.
- **Régression softmax** : $p(y = c \mid x) = e^{w_c^\top x} / \sum_j e^{w_j^\top x}$, minimisation de l'entropie croisée $-\sum_i \log p(y_i \mid x_i)$, fonction *convexe* à gradient explicite.
- **SVM linéaire** : perte hinge régularisée $\frac{1}{2} \|w\|^2 + C \sum_i \max(0, 1 - y_i(w^\top x_i + b))$ (cf. 6.2).

6.2 SVM à marge maximale : dérivation

Primal (marge dure). Pour des données séparables, $y_i \in \{\pm 1\}$, l'hyperplan $w^\top x + b = 0$ a une marge $2/\|w\|$; la maximiser revient à

$$\min_{w,b} \frac{1}{2}\|w\|^2 \quad \text{s.c.} \quad y_i(w^\top x_i + b) \geq 1 \quad \forall i. \quad (1)$$

Marge souple. Pour des données non séparables, on relâche par des écarts $\xi_i \geq 0$:

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C \sum_i \xi_i \quad \text{s.c.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad (2)$$

dont l'optimum donne $\xi_i = \max(0, 1 - y_i(w^\top x_i + b))$: la perte *hinge*.

Lagrangien. Avec $\alpha_i \geq 0$ (marge) et $\mu_i \geq 0$ ($\xi_i \geq 0$),

$$\mathcal{L} = \frac{1}{2}\|w\|^2 + C \sum_i \xi_i - \sum_i \alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i.$$

L'annulation des dérivées donne les conditions stationnaires

$$w = \sum_i \alpha_i y_i x_i, \quad \sum_i \alpha_i y_i = 0, \quad \alpha_i = C - \mu_i. \quad (3)$$

Dual. En réinjectant,

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \quad \text{s.c.} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0. \quad (4)$$

Problème quadratique concave où les données n'interviennent *que* par produits scalaires.

KKT et vecteurs supports. La complémentarité $\alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] = 0$ impose $\alpha_i \neq 0$ uniquement pour les points sur ou dans la marge — les **vecteurs supports** : la solution n'en dépend que d'eux (96 % des points ici, donnée difficile).

Kernel trick. Tout passant par $\langle x_i, x_j \rangle$, on substitue un noyau $k(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle$. Pour un noyau symétrique défini positif, une telle application φ existe (théorème de Mercer), et la solution s'écrit $w = \sum_i \alpha_i y_i \varphi(x_i)$, d'où le classifieur $f(x) = \sum_i \alpha_i y_i k(x_i, x) + b$. Le RBF $k(x, x') = \exp(-\gamma\|x - x'\|^2)$ correspond à un φ de dimension infinie.

6.3 Passage à l'échelle : approximation de Nyström

La matrice de Gram exacte $K \in \mathbb{R}^{n \times n}$ est inabordable pour $n = 50\,000$. On l'approche par une matrice de **rang faible** $m \ll n$. Soit m points de référence (*landmarks*) et les blocs

$$C \in \mathbb{R}^{n \times m} \text{ (noyau tous } \times \text{ landmarks)}, \quad W \in \mathbb{R}^{m \times m} \text{ (landmarks } \times \text{ landmarks)},$$

$$\boxed{\tilde{K} = C W^+ C^\top} \quad (\text{rang} \leq m), \quad (5)$$

W^+ étant le pseudo-inverse. **Carte de features explicite** : diagonalisons $W = U \Lambda U^\top$ et posons $Z = C U \Lambda^{-1/2} \in \mathbb{R}^{n \times m}$. Alors

$$Z Z^\top = C U \Lambda^{-1} U^\top C^\top = C W^+ C^\top = \tilde{K}, \quad (6)$$

si bien que $\langle z_i, z_j \rangle \approx k(x_i, x_j)$: on a *rendu le noyau explicite*. Le SVM à noyau devient un SVM *linéaire* dans $\mathbb{R}^m$ (coût $O(nm)$), applicable aux 50 000 images sans jamais former K .

Pourquoi cela fonctionne. Si le spectre de K décroît vite (cas du RBF), K est presque de rang faible et $\tilde{K}$ en est une bonne reconstruction, comme pour Eckart–Young en PCA (§7.1). L’erreur relative mesurée $\|K - \tilde{K}\|_F / \|K\|_F$ vaut 0.167, 0.093, 0.059 pour $m = 50, 150, 400$: elle chute vite, ce qui confirme cette décroissance du spectre.

6.4 Résultats et choix

Modèle	données	acc. test
k -NN ($k=10$)	10k/2k	0.281
Softmax	10k/2k	0.292
SVM linéaire (hinge)	10k/2k	0.308
SVM RBF <i>exact</i>	10k/2k	0.479
Nyström RBF $m=500$	50k /10k	0.481
Nyström RBF $m=1000$	50k /10k	0.504

Choix. Le RBF est retenu (non-linéarité nécessaire : le linéaire plafonne à 0.31). Nyström sur 50 000 atteint la précision du RBF exact sur 10 000 *pour un coût comparable* : à budget égal, il vaut mieux plus de données via une approximation contrôlée que le noyau exact sur peu de données. En pixels bruts on plafonne toutefois vers 0.50 : la limite est la *représentation*, d’où l’exercice 7.

7 Exercice 7 — Représentations non supervisées

On apprend une application φ *sans étiquettes*, puis on teste les latents par une **sonde linéaire** (classifieur linéaire sur représentations gelées, 10 000 exemples d’entraînement, test complet). Une bonne représentation rend la tâche *linéairement* séparable.

Choix du scoring. L’étape non supervisée (PCA, K -means) n’utilise pas les étiquettes ; on ne peut donc pas la noter directement par une précision. On choisit comme score la **précision de la sonde linéaire** : elle mesure exactement ce qui nous intéresse, à savoir si la représentation rend les classes *linéairement* séparables, et reste comparable d’une représentation à l’autre (même classifieur, même taille d’entraînement). Une mesure non supervisée interne comme l’inertie du K -means renseignerait sur la compacité des amas mais pas sur leur utilité pour la classification, qui est notre but.

7.1 PCA : dérivation (Eckart–Young)

Sur données centrées, covariance $\Sigma = \frac{1}{n}X^\top X = U\Lambda U^\top$, $\lambda_1 \geq \dots \geq \lambda_d \geq 0$. Deux lectures équivalentes : *variance maximale* ($\arg \max_{\|u\|=1} u^\top \Sigma u = u_1$, quotient de Rayleigh) et *reconstruction minimale* ($\min \sum_i \|x_i - Px_i\|^2$ sur les projecteurs de rang k), donnant le même $U_k = [u_1, \dots, u_k]$.

Théorème d’Eckart–Young. $X_k = XU_kU_k^\top$ est la meilleure approximation de rang k de X (normes de Frobenius et spectrale), d’erreur $\sum_{j>k} \lambda_j$. C’est ce qui justifie de garder les premières composantes comme représentation. Mesuré : variance cumulée 0.86 à $k=64$, 0.96 à $k=256$.

7.2 Dictionnaire K -means (Coates & Ng)

K -means apprend K centroïdes minimisant $\sum_i \min_k \|p_i - c_k\|^2$ (algorithme de Lloyd : assignation $\leftrightarrow$ moyenne, décroissance monotone, convergence vers un minimum local) : une quantification vectorielle servant de *dictionnaire*. La métrique est la **distance euclidienne**, cohérente

avec l’objectif quadratique de K -means et appliquée *après* blanchiment ZCA, qui décorrèle les pixels pour que cette distance ne soit pas faussée par leurs corrélations. Pipeline :

1. patches $6 \times 6 \times 3$ aléatoires, normalisés en contraste (centrage + variance unité) ;
2. **blanchiment ZCA** $p \mapsto Wp$, $W = U(\Lambda + \varepsilon I)^{-1/2}U^\top$ (covariance des patches) : décorrélacion — encore le théorème spectral ;
3. dictionnaire : K -means sur patches blanchis ;
4. encodage *triangle* $f_k(p) = \max(0, \bar{d}(p) - \|p - c_k\|)$ (code parcimonieux, non négatif), $\bar{d}$ distance moyenne aux centroïdes ;
5. **pooling** par quadrants $2 \times 2 \Rightarrow 4K$ features, passées à un SVM linéaire.

Intuition : blanchiment + K -means fabriquent des détecteurs de bords/couleurs ; le pooling apporte l’invariance ; la tâche devient linéairement séparable.

7.3 Résultats et choix

Représentation	dim	acc. test (sonde lin.)
Pixels bruts	3072	0.323
PCA	256	0.380
Dictionnaire K-means	1024	0.659

Choix. À classifieur *linéaire fixé*, passer des pixels au dictionnaire K -means double quasiment la précision ($0.32 \rightarrow 0.66$), et sans étiquette : la difficulté de CIFAR est surtout dans la représentation, pas dans le classifieur. Augmenter K (jusqu’à 1600) pousse vers ~ 0.77 (Coates & Ng) ; on garde $K=256$ pour un temps de calcul modéré.

8 Conclusion

On retrouve deux outils principaux. D’une part l’optimisation convexe : le SVM se résout via son dual (KKT, vecteurs supports), le kernel trick déplace la non-linéarité, et Nyström permet le passage à l’échelle. D’autre part la diagonalisation des matrices symétriques (théorème spectral), qui sert pour la PCA, le blanchiment ZCA et le bloc W de Nyström. Le gain décisif vient finalement de l’apprentissage non supervisé de représentations (K -means, PCA) plutôt que du choix du classifieur.